波動率群聚與 GARCH

第三週 — 財務管理：波動率、風險與人工智慧

Yi-Hao Lai

2026 Spring

今日學習路徑

1. 故事：為什麼這很重要
2. 偵測波動率群聚
3. 從 ARCH 到 GARCH
4. 均值回歸與半衰期
5. 最大概似估計
6. Python 即時演示
7. 應用：COVID 崩盤
8. 重點回顧

1

故事：為什麼這很重要

VolTech 的挑戰

上週：Alex Chen 建立了 EWMA 波動率儀表板。

本週的問題：EWMA 衡量的是當前的波動率。我們能預測它**明天**會是多少嗎？

可以 — 因為波動率具有記憶。

Mandelbrot (1963)

「大的變動往往接著大的變動 — 不論方向 — 小的變動接著小的變動。」

今日學習目標

在本節課結束後，你將能夠：

1. 使用平方報酬率的 ACF 偵測波動率群聚（Volatility Clustering）
2. 理解 ARCH 模型的基礎
3. 精通 GARCH(1,1) 方程式及其三個參數
4. 解釋 GARCH 為何優於 EWMA（均值回歸）
5. 使用 Python 的 `arch` 套件估計 GARCH(1,1)

2

偵測波動率群聚

報酬率 vs. 平方報酬率

原始報酬率 r_t：

- 近似不相關
- 方向不可預測

平方報酬率 r_t^2：

- 強自相關
- **幅度**可以預測

關鍵洞見

報酬率就像**風的方向** — 難以預測。平方報酬率就像**風的強度** — 當暴風雨開始時，它不會突然停止。

Ljung–Box 檢定

Ljung–Box 統計量

$$Q(m) = T(T+2)\sum_{k=1}^{m}\frac{\hat{\rho}(k)^2}{T-k} \sim \chi^2(m) \quad \text{在} H_0 \text{ 下}$$

- H_0：平方報酬率無自相關
- 小 p 值（< 0.05）$\Rightarrow$ 拒絕 H_0 $\Rightarrow$ 確認波動率群聚
- 在實務中：對金融資料幾乎必定拒絕

3

從 ARCH 到 GARCH

報酬率分解

基本構件

$$r_t = \sigma_t z_t, \qquad z_t \sim \text{i.i.d.}(0, 1)$$

- $\sigma_t =$ **條件波動率（Conditional Volatility）**（隨時間變化的「音量旋鈕」）
- $z_t =$ 標準化衝擊（隨機的「方向」）
- 目標：建模 σ_t 如何隨時間演變

ARCH 模型（Engle, 1982）

ARCH(q)

$$\sigma_t^2 = \omega + \alpha_1 r_{t-1}^2 + \alpha_2 r_{t-2}^2 + \cdots + \alpha_q r_{t-q}^2$$

- 今天的變異數取決於近期過去的平方報酬率
- 如果昨天的 $|r_{t-1}|$ 很大 $\Rightarrow$ σ_t^2 就很大 $\Rightarrow$ **群聚**
- 問題：需要許多落後期 q 才能實現合理的衰減 $\Rightarrow$ 參數過多

GARCH(1,1)：主力模型（Bollerslev, 1986）

GARCH(1,1)

$$\sigma_t^2 = \omega + \alpha\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

參數	角色	典型值
ω	下限 / 基礎變異數	小的正數
α	對新衝擊的反應	0.05–0.15
β	記憶 / 持續性	0.80–0.95
$\alpha + \beta$	總持續性	0.95–0.99

為什麼只需要 3 個參數？

GARCH(1,1) = ARCH(∞)

透過遞迴代入：

$$\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{i=1}^{\infty} \beta^{i-1} r_{t-i}^2$$

- β 項透過指數衰減編碼了**整個歷史**
- 一個 GARCH 落後期取代了無限多個 ARCH 落後期
- 三個數字就能捕捉大多數金融資產的波動率動態

4

均值回歸與半衰期

GARCH vs. EWMA：缺失的那塊

EWMA（$\omega = 0$）：

$$\sigma_t^2 = (1-\lambda)\, r_{t-1}^2 + \lambda\, \sigma_{t-1}^2$$

- 無均值回歸
- 衝擊後波動率持續漂移

GARCH（$\omega > 0$）：

$$\sigma_t^2 = \omega + \alpha\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

- 均值回歸至 $\frac{\omega}{1-\alpha-\beta}$
- ω 扮演**彈簧**的角色

關鍵差異

在衝擊之後，GARCH 會將波動率拉回其長期水準。EWMA 沒有錨點 — 它會無限期地漂移。

長期變異數與半衰期（Half-Life）

長期（無條件）變異數

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}$$

波動率半衰期（Half-Life）

$$h = \frac{\ln(0.5)}{\ln(\alpha + \beta)}$$

5

最大概似估計

如何找到 ω、α、β？

對數概似函數（高斯）

$$\mathcal{L} = -\frac{1}{2}\sum_{t=1}^{T}\left[\ln(2\pi) + \ln(\sigma_t^2) + \frac{r_t^2}{\sigma_t^2}\right]$$

MLE 演算法：

1. 初始化 σ_1^2（樣本變異數）
2. 對候選的 (ω, α, β)：遞迴計算 $\sigma_2^2, \ldots, \sigma_T^2$
3. 評估對數概似值
4. 最佳化器搜尋最大值

實務上：使用 Student-t 分配（$\nu \approx 5$–7）以適應殘差的厚尾。

6

Python 即時演示

步驟一：視覺化群聚現象

```python
import numpy as np, pandas as pd
import yfinance as yf
import matplotlib.pyplot as plt

sp500 = yf.download("^GSPC",
    start="2015-01-01", end="2024-12-31")
prices = sp500["Close"].squeeze()
returns = 100 * np.log(
    prices / prices.shift(1)).dropna()

fig, axes = plt.subplots(2, 1, figsize=(14, 8))
axes[0].plot(returns, linewidth=0.5)
axes[0].set_title("Daily Log Returns (%)")
axes[1].plot(returns ** 2, color="red",
    linewidth=0.5)
axes[1].set_title("Squared Returns")
```

步驟二：Ljung–Box 檢定

```python
from statsmodels.stats.diagnostic import (
    acorr_ljungbox)
from statsmodels.graphics.tsaplots import plot_acf

# ACF: raw returns (flat) vs. squared (persistent)
fig, axes = plt.subplots(1, 2, figsize=(14, 4))
plot_acf(returns.values, lags=30, ax=axes[0],
    title="ACF of Returns")
plot_acf(returns.values ** 2, lags=30, ax=axes[1],
    title="ACF of Squared Returns")

lb = acorr_ljungbox(returns ** 2, lags=10,
    return_df=True)
print(lb)  # Very small p-values!
```

步驟三：配適 GARCH(1,1)

```python
from arch import arch_model

model = arch_model(returns, vol="Garch",
    p=1, q=1, dist="t")
result = model.fit(disp="off")
print(result.summary())

omega = result.params["omega"]
alpha = result.params["alpha[1]"]
beta  = result.params["beta[1]"]

print(f"alpha + beta = {alpha + beta:.4f}")
print(f"Long-run vol = {np.sqrt(omega /
    (1-alpha-beta) * 252):.2f}% ann.")
print(f"Half-life = {np.log(0.5) /
    np.log(alpha+beta):.1f} days")
```

步驟四：條件波動率圖

```
cond_vol = result.conditional_volatility

fig, ax = plt.subplots(figsize=(14, 6))
ax.plot(returns.index, returns,
    color="gray", linewidth=0.4, alpha=0.6)
ax.plot(cond_vol.index, cond_vol,
    color="red", linewidth=1.5,
    label="GARCH cond. vol")
ax.plot(cond_vol.index, -cond_vol,
    color="red", linewidth=1.5)
ax.fill_between(cond_vol.index,
    cond_vol, -cond_vol, alpha=0.1,
    color="red")
ax.legend()
```

7

應用：COVID 崩盤

起始問題

測試：在 COVID 前（2020 年 1 月前）估計 GARCH，然後預測到崩盤期間。

結果：GARCH 的反應偏慢：

- 第 1 天：市場下跌 3%。GARCH 幾乎沒動（$\beta \times \sigma_{t-1}^2$ 主導）
- 第 2–3 天：仍低於實現波動率
- 第 5 天以後：終於追上

為什麼？

GARCH 是**反應式**的，不是前瞻式的。它只在 觀察到大報酬率之後才更新。而 VIX 在最嚴重的報酬率之前就已飆升。

模型診斷

GARCH 配適後，檢查標準化殘差 $\hat{z}_t = r_t/\hat{\sigma}_t$：

1. **對 $\hat{z}_t^2$ 做 Ljung–Box 檢定**：p 值應該很大 $\Rightarrow$ 群聚已被消除
2. **$\hat{z}_t^2$ 的 ACF**：應該是平坦的（相對於原始平方報酬率）
3. **偏態**：仍然是負值（≈ -0.3）

殘餘問題

負偏態 $\Rightarrow$ GARCH 無法捕捉**槓桿效應（Leverage Effect）**。它使用 r_{t-1}^2，這會抹除符號。

-3% 的一天和 $+3\%$ 的一天被視為完全相同。

8

重點回顧

六大重點

1. **波動率會群聚**：透過 r_t^2 的 ACF 和 Ljung–Box 檢定可以偵測到
2. **ARCH**：今天的變異數取決於過去的平方報酬率。需要許多落後期。
3. **GARCH(1,1)**：三個參數（ω, α, β）捕捉大部分的波動率動態
4. **均值回歸**：$\bar{\sigma}^2 = \omega/(1-\alpha-\beta)$ 是 EWMA 所缺少的（$\omega = 0$）
5. **MLE**：選擇使資料機率最大化的參數。Student-t 改善尾部配適。
6. **局限**：GARCH 對 r_{t-1} 取平方，抹除符號 $\Rightarrow$ 無法捕捉槓桿效應

任務三：建構 GARCH 引擎

交付項目

1. 下載 Nikkei 225 和 S&P 500（2010–2024）
2. 每個指數的 ACF 圖和 Ljung–Box 檢定
3. 對每個指數配適 Student-t 的 GARCH(1,1)
4. 報告：$\hat{\omega}$、$\hat{\alpha}$、$\hat{\beta}$、長期波動率、半衰期
5. 診斷圖：平方標準化殘差的 ACF
6. 比較 GARCH 與 EWMA 的條件波動率

下週預告

第四週：非對稱波動率 — GJR-GARCH

Alex Chen 發現 -3% 的一天對明天波動率的影響，遠大於 $+3\%$ 的一天。

GARCH 對這種非對稱性是盲目的。

主題：槓桿效應、GJR-GARCH、EGARCH、新聞衝擊曲線（News Impact Curve）、概似比檢定（Likelihood Ratio Test）