波動率預測

第五週 — 財務管理：波動率、風險與人工智慧

Yi-Hao Lai

2026 Spring

今日學習路徑

1. 故事：預測競賽
2. 預測框架
3. 波動率代理變數問題
4. 損失函數
5. Mincer–Zarnowitz 迴歸
6. Python 實作
7. Diebold–Mariano 檢定
8. 競賽結果
9. AI 焦點：GARCH vs. 深度學習
10. 重點摘要

1

故事：預測競賽

預測競技場

場景：Priya 帶著一個 LSTM 模型來到 VolTech。

「讓我的 LSTM 和你的 GARCH 一較高下。」

挑戰：哪個模型最能預測明天的波動率？

樣本內擬合 $\neq$ 樣本外預測

核心問題

你的模型能否預測它**從未見過**的波動率，還是只是在記憶過去？

今日學習目標

在本節課結束時，你將能夠：

1. 區分樣本內擬合與樣本外預測
2. 實作滾動視窗的一步前瞻預測
3. 使用 RMSE、MAE 和 QLIKE 評估預測
4. 執行 Mincer–Zarnowitz 迴歸
5. 使用 Diebold–Mariano 檢定比較模型

2

預測框架

樣本內 vs. 樣本外

樣本內（估計）：

- 模型「看到」所有數據
- 最佳化參數以擬合
- 可能記住噪音
- 像是模擬考

樣本外（評估）：

- 模型從未見過這些數據
- 預測未知的未來
- 測試真正的預測力
- 像是正式考試

⚠ 關鍵原則

完美擬合過去的模型可能是**過度擬合**（Overfitting）。唯一誠實的測試是樣本外。

滾動視窗預測

流程

1. 固定估計視窗為 W 個觀測值
2. 在第 $1, 2, \ldots, W$ 天上估計模型
3. 預測 $\hat{\sigma}^2_{W+1}$（一步前瞻）
4. 向前滾動：在第 $2, 3, \ldots, W+1$ 天上估計
5. 預測 $\hat{\sigma}^2_{W+2}$
6. 重複直到數據結束

關鍵：每次預測只使用過去的資訊。不會有未來數據洩漏。

滾動 vs. 擴展視窗

特徵	滾動	擴展
視窗大小	固定（W）	持續增長
舊數據	被丟棄	永遠保留
結構性斷裂	能適應	可能受污染
參數穩定性	較不穩定	較穩定
最適用於	變化的體制	穩定的環境

對股票市場而言：通常偏好滾動視窗，因為市場動態會隨時間演變。

3

波動率代理變數問題

我們在拿什麼做比較？

根本性的挑戰

我們永遠無法觀測到真實的波動率 σ_t^2。我們需要一個 **代理變數**（Proxy）來評估預測。

代理變數	精確度	所需數據
報酬率平方 r_t^2	非常低	只需日數據
全距法（Parkinson）	中等	OHLC
實現變異數 RV_t	高	日內（5 分鐘）

使用 r_t^2：所有模型看起來都很差（低 R^2），但 **排名是一致的**。

4

損失函數

RMSE：均方根誤差

RMSE

$$\text{RMSE} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(\sigma_t^{2*} - \hat{\sigma}_t^2)^2}$$

- 對**大誤差**施以重罰（平方）
- 適合偵測偶爾有糟糕預測的模型
- 對代理變數中的異常值敏感

MAE：平均絕對誤差

MAE

$$\text{MAE} = \frac{1}{T}\sum_{t=1}^{T}|\sigma_t^{2*} - \hat{\sigma}_t^2|$$

- **等比例**對待所有誤差
- 比 RMSE 對異常值更穩健
- 更容易解讀：「平均預測偏差」

QLIKE：黃金標準

QLIKE

$$\text{QLIKE} = \frac{1}{T}\sum_{t=1}^{T}\left(\ln(\hat{\sigma}_t^2) + \frac{\sigma_t^{2*}}{\hat{\sigma}_t^2}\right)$$

- 懲罰**相對**誤差（與尺度無關）
- 對波動率代理變數的選擇穩健（Patton, 2011）
- 當指標排名不一致時，**實務工作者偏好**的指標

經驗法則

當 RMSE 和 QLIKE 不一致時，相信 QLIKE。

為何需要多個損失函數？

性質	RMSE	MAE	QLIKE
大誤差懲罰	重	線性	相對
異常值穩健性	低	中	高
代理變數穩健性	低	低	**高**
可解釋性	高	高	中

最佳做法：報告全部三個。如果某個模型在所有指標上都勝出，結論就很明確。

5

Mincer–Zarnowitz 迴歸

檢驗預測效率

Mincer–Zarnowitz 迴歸

$$\sigma_t^{2*} = a + b\hat{\sigma}_t^2 + u_t$$

完美預測：$a = 0$，$b = 1$

解讀係數：

- $b < 1$：預測**過度反應**（變異太大）
- $b > 1$：預測**反應不足**（太平滑）
- $a \neq 0$：系統性**偏差**
- R^2：解釋的變異數比例

以 F 檢定聯合檢驗 $H_0 : a = 0,\ b = 1$。

理解 MZ 迴歸中的 R^2

不要為低 R^2 恐慌

對 r_t^2 代理：$R^2 \approx 5\text{–}15\%$ 是正常的。

對實現變異數 RV_t：$R^2 \approx 30\text{–}50\%$。

差異完全是由**代理變數的噪音**造成的，而非模型品質。

重要的是：模型的相對排名，而非絕對 R^2。

6

Python 實作

步驟一：預測設定

```python
import numpy as np, pandas as pd
import yfinance as yf
from arch import arch_model

sp500 = yf.download("^GSPC",
    start="2015-01-01", end="2024-12-31")
prices = sp500["Close"].squeeze()
returns = 100 * np.log(
    prices / prices.shift(1)).dropna()

window = 1000  # rolling estimation window
n_oos = len(returns) - window
print(f"Out-of-sample: {n_oos} days")
```

步驟二：滾動預測迴圈

```python
model_specs = {
    "GARCH":     {"vol":"Garch","p":1,"o":0,"q":1},
    "GJR-GARCH": {"vol":"Garch","p":1,"o":1,"q":1},
    "EGARCH":    {"vol":"EGARCH","p":1,"o":1,"q":1},
}
forecasts = {}
for name, spec in model_specs.items():
    fc = np.full(n_oos, np.nan)
    for i in range(n_oos):
        train = returns.iloc[i:i + window]
        model = arch_model(train, dist="t", **spec)
        res = model.fit(disp="off")
        fv = res.forecast(horizon=1)
        fc[i] = fv.variance.values[-1, 0]
    forecasts[name] = pd.Series(
        fc, index=returns.index[window:])
```

步驟三：評估指標

```python
realized = returns.iloc[window:] ** 2

def evaluate(realized, forecasts):
    results = {}
    for name, fc in forecasts.items():
        r, f = realized.values, fc.values
        f = np.maximum(f, 1e-10)
        rmse = np.sqrt(np.mean((r - f)**2))
        mae  = np.mean(np.abs(r - f))
        qlike = np.mean(np.log(f) + r / f)
        results[name] = {"RMSE": rmse,
            "MAE": mae, "QLIKE": qlike}
    return pd.DataFrame(results).T

print(evaluate(realized, forecasts).round(4))
```

步驟四：Mincer–Zarnowitz 迴歸

```python
import statsmodels.api as sm

for name, fc in forecasts.items():
    r = realized.values
    f = fc.values
    X = sm.add_constant(f)
    ols = sm.OLS(r, X).fit()
    a, b = ols.params
    r2 = ols.rsquared
    f_test = ols.f_test("(const = 0), (x1 = 1)")
    print(f"{name:<14} a={a:.4f} b={b:.4f} "
          f"R2={r2:.4f} p={float(f_test.pvalue):.4f}")
```

預期：GJR-GARCH 的 b 最接近 1 且 R^2 最高。

7

Diebold–Mariano 検定

正式比較兩個模型

Diebold–Mariano 檢定

$$d_t = L(\hat{\sigma}^2_{1,t}) - L(\hat{\sigma}^2_{2,t})$$

$$DM = \frac{\bar{d}}{\hat{\sigma}_{\bar{d}}} \xrightarrow{d} N(0,1)$$

- H_0：兩個模型具有相等的預測準確度
- $|DM| > 1.96$：其中一個模型顯著較好（5%）
- 使用 **HAC 標準誤**（Newey–West），因為預測誤差具有序列相關

步驟六：Python 中的 DM 檢定

```python
from scipy import stats

def dm_test(realized, fc1, fc2):
    r, f1, f2 = realized.values, fc1.values, fc2.values
    L1 = np.log(f1) + r / f1  # QLIKE losses
    L2 = np.log(f2) + r / f2
    d = L1 - L2
    T = len(d)
    lag = int(T ** (1/3))
    gamma_0 = np.var(d, ddof=1)
    gamma_sum = sum((1-k/(lag+1)) *
        np.cov(d[k:], d[:-k])[0,1]
        for k in range(1, lag+1))
    var_d = (gamma_0 + 2*gamma_sum) / T
    dm = d.mean() / np.sqrt(max(var_d, 1e-20))
    p = 2*(1 - stats.norm.cdf(abs(dm)))
    return dm, p
```

8

競賽結果

誰贏了？

模型	RMSE	MAE	QLIKE
GARCH(1,1)	5.82	2.14	3.72
GJR-GARCH(1,1)	**5.61**	**2.03**	**3.65**
EGARCH(1,1)	5.65	2.10	3.66

GJR-GARCH 在所有三個指標上都獲勝。

槓桿效應不僅是更好的樣本內擬合 — 它提供了**真正的預測力**。

關鍵發現

1. **GJR-GARCH 持續優於 GARCH**，跨所有損失函數（DM 檢定確認：$p < 0.01$）
2. **EGARCH 表現類似 GJR-GARCH** — 兩個不對稱模型都捕捉了槓桿效應
3. **改善幅度不大但一致** — 不要期待巨大的收益；波動率本來就很難預測
4. **所有模型在危機初期都表現不佳** — COVID 的最初幾天，每個模型的預測都很差

9

AI 焦點：GARCH vs. 深度學習

GARCH vs. ML 辯論

期間	GARCH	ML/DL
1–5 天	**有競爭力**	邊際收益
1–4 週	良好的基準線	**有優勢**
1 個月以上	表現困難	**明顯優勢**

為何 GARCH 在短期間難以被超越：

- 簡潔（3–4 個參數）：難以過度擬合
- β 項主導 1 天預測
- 以最少的假設捕捉關鍵的典型事實

最佳方法：混合模型 — GARCH 輸出作為 ML 模型的特徵，結合 VIX、交易量和情緒。

Priya 的 LSTM 結果

誠實的評估

- LSTM 在 RMSE 上微幅擊敗 GJR-GARCH $\sim$2%
- LSTM 在 QLIKE 上更差
- 訓練時間：慢 $100\times$
- 可解釋性：黑盒子

結論：GARCH 沒有過時。它是一個**強大的基準線**，任何 AI 模型都必須超越它才能證明其複雜度的合理性。

10

重點摘要

六件要記住的事

1. **樣本外才是真正的測試**：樣本內擬合可能因過度擬合而具有誤導性
2. **滾動視窗**：在固定長度的視窗上每天重新估計 — 黃金標準
3. **三個損失函數**：RMSE（大誤差）、MAE（平均偏差）、QLIKE（相對、代理穩健）
4. **Mincer–Zarnowitz**：檢驗預測效率（$a = 0$，$b = 1$）
5. **Diebold–Mariano**：檢驗差異是否統計顯著
6. **GJR-GARCH 擊敗 GARCH**：槓桿效應為股票提供真正的預測力

任務五：預測競賽

交付成果

1. 對日經 225 和 S&P 500 進行 GARCH 和 GJR-GARCH 的滾動預測（$W = 1000$）
2. 計算每個模型的 RMSE、MAE、QLIKE
3. MZ 迴歸：報告 $\hat{a}$、$\hat{b}$、R^2、F 檢定 p 值
4. 每個指數的預測比較圖
5. 200 字報告：VolTech 應該部署哪個模型？

加分：使用擴展視窗重複並比較結果。

下週預告

第六週：風險值（Value-at-Risk）

Kenji 問道：「在 99% 的信心下，我們明天最多會虧多少？」

我們將波動率預測轉化為每家銀行每天都會計算的那個數字。

主題：參數 VaR、歷史模擬法、期望損失、回測